Napredni algoritmi i strukture podataka

SSTable, Index, Summary, Struktura, Formiranje

Univerzitet u Novom Sadu
Fakultet Tehničkih Nauka

Memtable - rekapitulacija

- Memtable ideja je relaltivno jednostavna — zapisati podatke u memorju i čitati podatke iz memorije
- Memorija je brza, memorija je super, memorija je kul
- **ALI** nemamo beskonačno memorije (recite to matematičarima :))
- **AKO** se podaci nalaze u memoriji, sve operacije su relativno brže nego da su podaci **striktno** na disku
- **ALI** memorija nije sigurna :/

- Restart sistema i naših podataka više nema (objansite to korisnicima:))
- Iz tog razloga nam treba snažna garancija trajnosti podataka
- Memtable komunicira sa WAL-om, koji nam daje ove garancije
- Ovaj princip se pokazuje jako korisno kod **write-heavy** problema
- Kada se Memtable struktura popuni, ona se perzistira na disk (Flush) i pravi se **SSTable** koja je neprimenljiva
- Veličinu Memtable-a, možemo podešavati

Prošli put jako malo o SSTable

1. SSTable se sastoji od nekoliko elemenata
2. Sve ove elemente je potrebno formirati kada se formira SSTable
3. Uopšteno gledano, SSTable ima **index** deo – lakše pozicioniranje na potrebne delove **data** segmenta, koji čini drugi deo
4. Korišćenje **Memtable**, **WAL** i **SStable** je poznato kao **write-path**

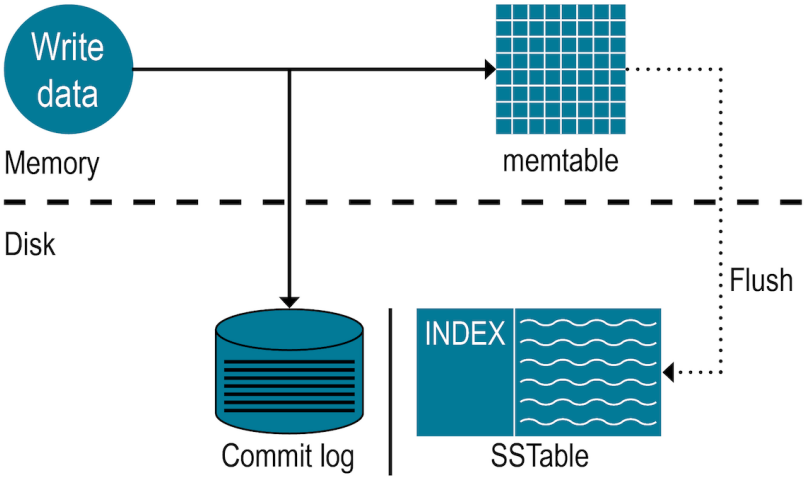

(Cassandra write path)

SStable - ideja

- Ideja iza tabele sortiranih stringova (**SSTable**) je relativno jednostavna
- To je niz parova **ključ-vrednost** koji su sortirani, i zapisani na disk
- **SStable** je nepromenljiva struktura (log based struktura) — nema brisanja ni izmene sadržaja
- Memtable zapisati na disk, sa relativno sličnom strukturom (ako ne i istom)

- Zavisi od toga šta čuvate, i kakav vam je **model podataka**
- Zavisi od upotrebe!
- Pod nizom sortiranih stringova ne misli se doslovno na stringove, već na **niz bajtova**
- Ključ će biti **string** to svkako, ali vrednost može biti bilo šta
- Zbog toga je najjednostavnije da se čuva niz bajtova

SSTable — Tombstone

- Kada se obriše podatak, on nije momentalno uklonjen sa diska
- Sistem zapisuje specijalan podatak *Tombstone* da je neki ključ obrisan — markira ga za brisanje
- Brisanje elemenata je zapravo **nov zapis** u SStable — SSTable je nepromenljiva struktura
- Fizičko brisanje sa diska se odvija kada se desi specifičan proces — kompakcije

Pitanje 1

Kakvu strukturu da koristimo, ideje :) ?

SStable — struktura

- Izabraćemo opšti oblik SSTable-a
- Niz parova **ključ-vrednost**, gde su obe vrednosti zapravo niz bajtova
- Pre zapisa Memtabe-a, sve vrednosti se **sortiraju** — ovo nam trebati kasnije!!
- Ovim smo dobili **data** segment
- Svi podaci se nalaze tu

Opšta struktura SSTable

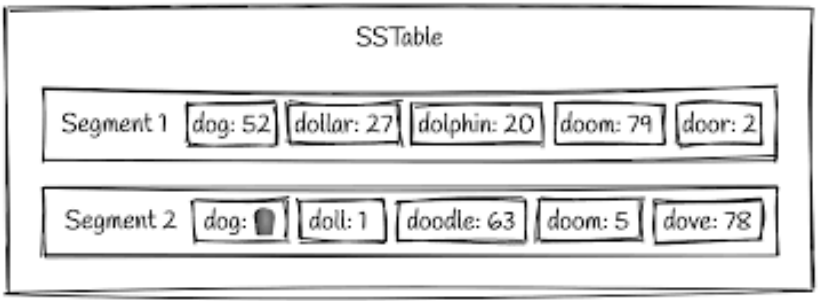

(LSM — Write Heavy Databases)

- Prethodna slika ne kazuje baš puno :(
- Vidimo markiranje ključeve za brisanje — Tombstone
- Vidimo nekakve segmente i nekakve parove **ključ-vrednost**, ali šta sa njima...
- Ali bar vidimo neku opštu ideju
- Hajde da vidimo, kako to rešavaju velikani (Niko sa teritorije Novog Sada :))
- Da vidimo konkretnu strukturu nekakvog sistema

Opšta struktura SSTable

```
<beginning_of_file>
[data block 1]
[data block 2]
...
[data block N]
[meta block 1]
...
[meta block K]
[metaindex block]
[index block]
[Footer]        (fixed size; starts at file_size - sizeof(Footer))
<end_of_file>
```

(LevelDB SSTable structure, Documentation)

- Vidimo da je SSTable podeljen na nekakve blokove podataka
- Ono što nas za sada najviše zanima je struktura **data block** dela
- Ostali podaci nam nisu toliko zabavni **za sada** — videćemo ih kasnije **Data block** sadrži konkretne podatke u parovima **ključ-vrednost**, CRC proverom, vremenskom odrednicom, ...
- **ALI** podaci su kompresovani, mi se time neće baviti — ako nekoga zanima može da pogleda kako se podaci mogu kompresovati zarad uštede prostora
- **ALI** ova strukutra nam je već donekle poznata — hajde da svedemo na nešto što već znamo

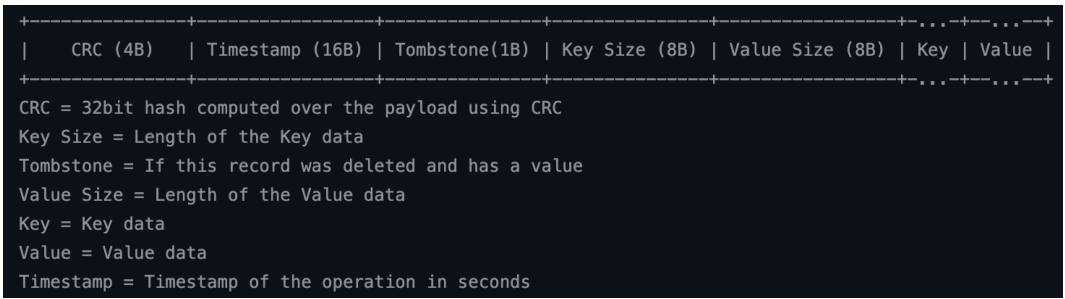
+---------------+-----------------+---------------+---------------+-----------------+-...-+--...--+
| CRC (4B) | Timestamp (16B) | Tombstone(1B) | Key Size (8B) | Value Size (8B) | Key | Value |
+---------------+-----------------+---------------+---------------+-----------------+-...-+--...--+
CRC = 32bit hash computed over the payload using CRC
Key Size = Length of the Key data
Tombstone = If this record was deleted and has a value
Value Size = Length of the Value data
Key = Key data
Value = Value data
Timestamp = Timestamp of the operation in seconds

- Ova ideja zapravo čini čitanje ovakve strukture **prilično sporo**
- Količina podataka koje jedna SSTable može da čuva može biti nekada izražena u Gigabajtima (pa i više)
- Veličina zavisi od konfiguracije i upotrebe
- Setite se kompleksnosti za **scan** operaciju kod struktura tipa log-a
- Da bi malo ubrzali ceo sistem, treba da napravimo dodatan deo — deo koji ubrzava **pretragu**
- Treba nam deo koji će se tačno pozicionirati na deo u fajlu gde je ključ — **index**

Pitanje 2

Kakvu strukturu da koristimo za index i šta on da čuva, ideje :) ?

SSTable — Index

- Ideja iza svakog index-a je da što je pre moguće stignete do konkretnog sadržaja
- Pogledajte index pojmova u (svakoj) knjizi
- Ista ideja se koristi i kod SSTable-a
- Struktura je relativno jednostavna
- Sastoji se od dve vrednosti:
  1. **ključ** koji se nalazi u fajlu na disku
  2. **offset** u fajlu, tj. pozicija u fajlu na disku
- Fajl na disku u ovom slučaju je SStable!
- Index bi bilo lepo sortirati (ne budite lenji, učinite sebi uslugu :))

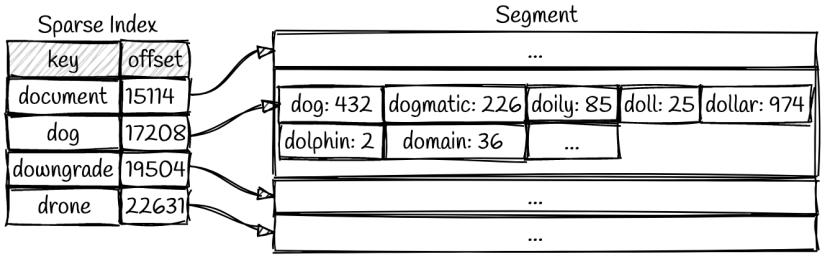

(LSM — Write Heavy Databases)

Pitanje 3

Da li nam ovo dovoljno? Vidite li probleme :)?

Index Summry

- Problem je vrlo jednostavan
- Vrlo lako može da se desi da imamo dosta SSTable struktura na disku
- Samim tim imamo i dosta Index struktura na disku
- To bi značilo da moramo otvoriti dosta fajlova da bi proverili da li je ključ tu ili ne
- Neki sistemi za skladištenje podataka (npr. Cassandra) koriste dodatan element za proveru
- Ovaj element se zove **Summary** koji može da čuva dva podataka
  1. **granice** index fajla — prvi i zadnji **ključ** u tom index-u
  2. **offset** ključa u index fajlu — poziciju u index fajlu

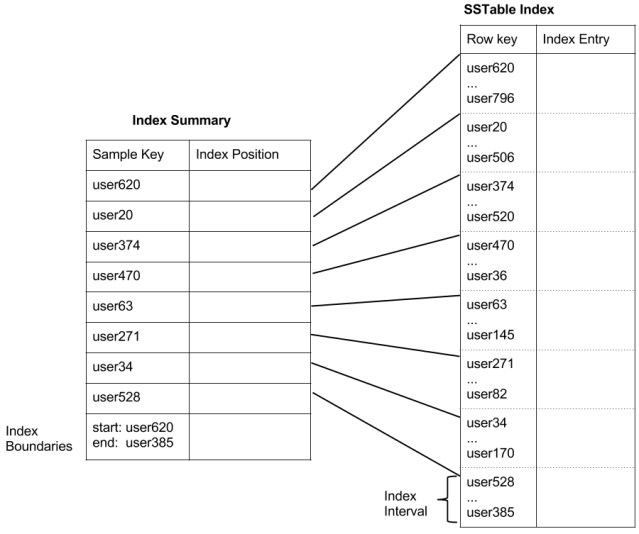

(Distributed Datastore, Summary)

Pitanje 4

Da li nam ovo dovoljno? Vidite li probleme :)?

- Malo smo smanjili broj čitanja
- Nećemo otvoriti svaki index fajl
- Otvorićemo svaki $n - ti$ fajl
- Situacija je bolja, ali i dalje imamo manje više isti problem
- To nas dovodi do toga da je ideja da je SStable sastavljena **samo** od index i data dela **pogrešna** :(
- Pa hajde da vidimo šta konkretni sistemi čuvaju sve od podataka

SSTable struktura

- Za primer, možemo da vidmo postojeći sistem za skladištenje podataka — Cassanda
- Ovaj sistem čuva svoje podatke na jednom mestu (kao i WAL)
- Na slici pored, vidimo da imamo dosta više delova od samo index-a i data dela :O
- **usertable-data-ic-1-TOC.txt** fajl sadrži spisak svih fajlova za konkretan SSTable

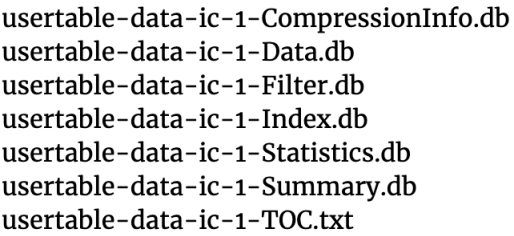

(Distributed Datastore, SSTable format)

- Veći deo sa ovog spisak smo već prošli
- Sve nam neće trebati, zato što nećemo praviti sistem za produkciju
- Kompresiom podatka se isto nećemo baviti
- Stoga, *CompressionInfo* i *Statistics* delove možemo da zanemarimo
- *TOC*, *Data*, *Index*, *Summry* znamo šta je
- Poslednja stvar koja nam ostaje, a koja nam najviše pomaže da **znatno** ubrzamo proces čitanja je deo **Filter**

Pitanje 5

Poslednja stvar koja nam ostaje, a koja nam najviše pomaže da **znatno** ubrzamo proces čitanja je deo **Filter**

Čemu služi filter, ideje :)?

- Pa kao što mu ime kaže treba da filtriramo **nešto**
- **ALI** podataka može biti jako puno
- Sistemi kao što su Cassandra, Dynamo, RocskDB itd. čuvaju enormen količine podataka i to na vše čvorova!
- Ako moramo da negde čuvamo sve ključeve, opet ništa nećemo postići :(
- Treba nekako da potrošimo što manje resursa da nam kaže da ključ nije **sigurno** prisutan, da možemo da pitamo dalje

Pitanje 6

Treba nekako da potrošimo što manje resursa da nam kaže da ključ nije **sigurno** prisutan, da možemo da pitamo dalje...

Da li smo radili nešto ovako, ideje :)?

Filter

- **BLOOM FILTER :D**!!!
- **Filter** je zapravo zapisan **Bloom filter** na disk za nekakv skup ključeva
- Bloom filter se pita, **PRE** bilo kakvog indexa, da li se traženi ključ tu **ne** nalazi ili se **možda** nalazi
- Ako se **ne** nalazi, nema potrebe da otvaramo išta, možemo da gledamo dalje
- Ako je ključ **možda** tu, onda moramo proveriti, i za provere koristimo index strukture!!
- Njih koristimo da brže stignemo do podatka, **AKO** je ključ tu

Pitanje 7

Ali Bloom filter ožahteva da mu se sepcificira koliko zapisa se očekuje da on skaldišti...

ideje :)?

- Bloom Filter-u trebamo da kažemo koliko elemenata se očekuje, ali to nije sada problem
- Ovaj podatak nam je unapred poznat, pošto tačno znamo koliko elemenata čuva Memtable
- SSTable isto zna tačno zna koliko će elemenata biti sačuvano
- Samim tim i za Bloom Filter imamo tu informaciju unapred poznatu!
- Stoga, sve elemente možemo formirati ispravno

Formiranje SSTabele

- Kada se Memtable napuni, ona se zapisuje na disk i formira SSTable
- Koristeći dostupne podatke dodatno formiramo;
  1. Bloom Filter za dostupnim kjučevima
  2. SSTable Index pošto znamo na kojoj poziciji u SSTable fajlu je koji ključ — sortirati
  3. SSTable Summary, pošto je SSTable Index već formiran i znamo pozicije ključeva — na početak staviti opseg, a ostatak sortirati
  4. TOC fajl u kom kažemo šta je sve od podatka dostpuno — svi prethodni elementi
- **ALI** ovde nije kraj :(

Finale

- Ostaje nam još **jedna stvar** koju dodatno treba da formiramo
- Dodatno formiramo *Metadata.txt* fajl o.O
- Potrebno je da formiramo **Merkle stablo** od podataka iz SSTable-a
- Nakon što je stablo formirano, stablo zapižemo u Metadata fajl
- Ovde je kraj pravljenja jednog SSTable-a
- **write path** je kompletan!
- Formiranje SSTable se obično odvija u pozadini, bez narušavanja rada sistema
- **Za vaš projekat ovo nije potrebno, može sve da se dešva i sinhrono**

Čitanje i pisanje sadržaja Memtable i SSTable

Write path smo videli prošli put, Read path radimo naredni put ali samo informativno...

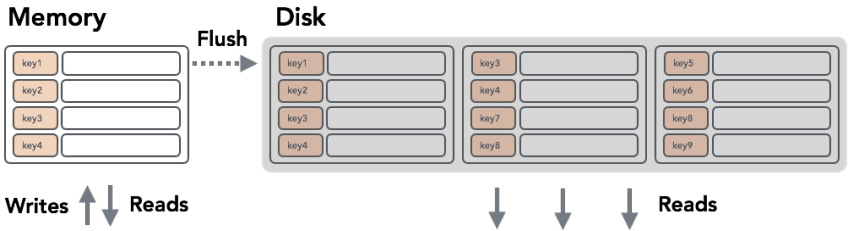

(Databases Internals)

Informativno, struktura Cassandra SSTable jb verzija

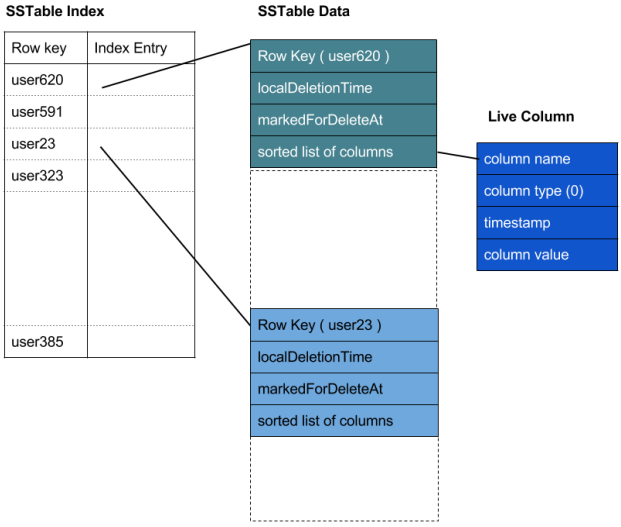

Dodatni materijali

- Database Internals: A Deep Dive into How Distributed Data Systems Work
- Dynamo: Amazon's Highly Available Key-value Store
- Cassandra - A Decentralized Structured Storage System
- Structured storage LevelDB
- Google BigTable paper
- System Overview: LevelDB

Pitanja

Pitanja :) ?